

Breve introducción a la gestión de Datos

Las compañías que hace décadas fueron incorporando tecnología a sus procesos, fueron de a poco recopilando, procesando y almacenando datos. Esto al principio se ha hecho en forma libre (ad hoc), cómo mejor podían los técnicos de ese momento. De este simple hecho se deduce el concepto de almacén de datos, de base de datos.

Pero yendo a la definición, ¿qué podemos considerar *"dato"*? Según Wikipedia, un dato es una expresión mínima de contenido sobre un tema. Vale decir, es una expresión atómica (indivisible) acerca de una propiedad de *"algo"*, por ejemplo un dato es que Carlos mide 1.90m o mejor dicho, la propiedad *"altura"* del sujeto *"Carlos"* es 1.90m. Esta medida, pensada cómo una instancia de una medición, es un dato.

Desde el punto de vista informático, *"el dato es una representación simbólica (numérica, alfabética, etc.), atributo o característica de una entidad. El dato no tiene valor semántico (sentido) en sí mismo, pero convenientemente tratado (procesado) se puede utilizar en la realización de cálculos o toma de decisiones"* (Wikipedia).

Desde el punto de vista del programador, *"un dato es la expresión general que describe las características de las entidades sobre las cuales opera un algoritmo"*.

Ahora, pensándolo desde un punto de vista de procesamiento, este dato, ¿nos dice algo acerca de si Carlos es más alto que nosotros? ¿O nos dice algo sobre sus hábitos de consumo? Hay que tener en cuenta, que un dato por sí sólo es irrelevante (no tiene semántica). Quizás convendría decir, que a partir del procesamiento de datos, podemos obtener información.

La información, según wikipedia, *representa un conjunto de datos relacionados que constituyen una estructura de mayor complejidad (por ejemplo, un capítulo de un libro de ciencias)*. Este conjunto de datos que ha sido procesado tiene significado y relevancia (semántica), también se puede situar la información en un contexto, lo cuál vuelve a la información más interesante. Y quizás la podemos ir corrigiendo, lo cuál la hace más valiosa. También es posible categorizar la información, lo cuál la hace mucho más interpretativa.

Volvamos a la situación de alguna empresa que hace décadas invirtió en tecnología y logró que muchos de sus archivos (de papeles) desaparezcan, y estén de alguna u otra manera, digitalizados. Más allá del ahorro en costos de almacenamiento, y en cuánto al riesgo, ¿qué valor real agregado obtuvo la empresa, si pasó de tener un archivo ordenado por orden alfabético de los clientes (por poner un ejemplo), a tener un almacenamiento digital ad hoc que implementa la misma funcionalidad de orden alfabético únicamente? Seguramente el acceso al dato por el nombre del cliente será más rápido, pero parece ser que esta empresa deja de ganar muchos de los beneficios que le brindaría convertir (procesar) sus datos en información y explotarla en consecuencia. Es entonces cuándo la disciplina de la gestión de datos se convirtió en un desafío y se encararon investigaciones que hoy nos permiten manejar conceptos relativos a datos e información que hace décadas eran impensables.

También tengamos en cuenta que dicha empresa seguramente ha necesitado disponer de los datos en forma rápida; mucha gente consultando la misma información al mismo tiempo (conurrencia), ha necesitado también clasificar dicha información, ya sea por necesidades funcionales o por necesidades de seguridad dado que no sería óptimo que todo el mundo consulte la misma información; ha necesitado disponer de un mecanismo para que dos personas no modifiquen la misma información al mismo tiempo, o más bien para que uno de los dos sea consiente de la modificación del otro; ha necesitado asegurar la disponibilidad de la información a todo momento; disponer de respaldos ante accidentes, mal funcionamientos o desastres; ingresar los datos una sola vez (redundancia mínima), mantener el conjunto de datos consistente e íntegro constantemente, ... Como vemos, estas fueron las causas que condujeron al desarrollo de sistemas administradores de bases de datos que contaran con estas características.

Podemos ensayar una definición de base de datos como *"un conjunto de datos relacionados entre sí de alguna manera"*. Hay algo que no cierra en esta definición y es lo que vimos anteriormente, implícitamente sabemos que algo caótico no es una base de datos, por lo que podríamos agregarle a nuestra definición que una base de datos es un conjunto de datos que son *"lógicamente coherentes"*. Hay cosas que faltan evidentemente en nuestra definición y creo tiene que ver con algo que también mencionamos, cuándo hablábamos de la base de datos de clientes de tal empresa unos párrafos arriba, podríamos estar infiriendo que una base de datos se construye para un fin específico, no existe la *"base de datos de la vida misma"*... Veamos la definición de Wikipedia:

"Una base de datos es un conjunto de datos que pertenecen al mismo contexto almacenados sistemáticamente para su posterior uso. En este sentido, una biblioteca puede considerarse una base de datos compuesta en su mayoría por documentos y textos impresos en papel e indexados para su consulta. En la actualidad, y debido al desarrollo tecnológico de campos como la informática y la electrónica, la mayoría de las bases de datos tienen formato electrónico, que ofrece un amplio rango de soluciones al problema de almacenar datos."

Ahora bien, existen sistemas que gestionan las bases de datos y nos permiten un acceso mejor a los datos, que son los Sistemas Gestores de Bases de Datos, o **DBMS** (Database Management Systems) que no son más que el software que le permite a los usuarios de las bases de datos, crear, administrar, consultar y destruir los datos. En el contenido de este texto, podemos llamara indistintamente DBMS, base de datos o motor de base de datos.

Los **DBMS** más difundidos implementan el modelo relacional para bases de datos. Que una base de datos sea relacional, implica varias cosas: que respeta un modelo matemático (pero simple) bien definido; y que ha sido sometida a un nivel de normalización (tercera forma normal por ejemplo).

Ya mencionamos que una base de datos es una colección de datos, y hemos dicho que no están dispuestos en forma caótica, ya que de esta manera no tiene objeto el gestionar una base de datos. Por tanto podemos deducir, que un DBMS gestiona tanto datos sobre una problemática en particular (un **dominio**, una base de datos de clientes), como datos de la manera en que se estructuran los datos de dicho **dominio**. Por ejemplo, sabemos que vamos a almacenar en nuestra base de datos las fechas en que los clientes compraron por primera vez, pero también almacenaremos que existe un campo llamado "fecha de alta" en determinada tabla que tiene tal dominio y tales restricciones. Este conjunto de datos acerca de la estructuración de los datos es conocido como *"Metadata"*. Entonces, podremos hablar de *"data"* y de *"metadata"* de una base de datos.