

Taller de Sizing

UCA Learn Analytics · almacenamiento físico


¿Cuánto almacenamiento necesita una base de datos que genera 1.200.000 eventos por día?

Hoy no hay entregable: la solución se construye en grupos y en el pizarrón.

Trabajo en grupos · no hay entregable · la solución se construye en el pizarrón

El modelo de datos

¿Dónde vive la tabla que vamos a dimensionar?



Foco del taller: events. Las demás tablas dan contexto al sistema relacional.

Tabla foco: events

Datos disponibles para empezar

Columna	Tamaño para el taller
event_id	8 B
student_id	8 B
course_id	4 B
event_ts	8 B
event_type	2 B
device	1 B
session_id	16 B
ip	16 B
payload_json	70%: 140 B · 30%: 900 B

Motor: página de 8 KB · espacio útil 8060 B · overhead simplificado 7 B/fila

Trabajo en grupos · no hay una única respuesta si el supuesto está explicitado

Desafío 1 — Tamaño de fila

¿Cuántos bytes ocupa, en promedio, una fila de events?

Escriban el cálculo. El payload no tiene siempre el mismo tamaño.

Pista solo si el grupo se traba: ¿cómo representarían una mezcla 70% / 30%?

Resolución 1 — Tamaño de fila

Comparen con el cálculo de su grupo

Payload promedio: $70\% \times 140 \text{ B} + 30\% \times 900 \text{ B} = 368 \text{ B}$

Otros campos: $8+8+4+8+2+1+16+16 = 63 \text{ B}$

Fila lógica = $63 \text{ B} + 368 \text{ B} = 431 \text{ B}$

Fila física = $431 \text{ B} + 7 \text{ B de overhead didáctico}$

438 bytes

70%/30% y 140/900 B son datos del caso. Los 7 B son el overhead simplificado usado en la clase.

Desafío 2 — Del registro a la página

4 minutos en grupos

Con 8060 B útiles por página y filas de 438 B...

1) ¿Cuántas filas entran por página? 2) ¿Cuántas páginas requiere un día? 3) ¿Cuánto storage es?

Volumen diario: 1.200.000 events · página física: 8 KB

Resolución 2 — Sizing de un día

El piso y el techo importan

$\text{floor}(8060 \text{ B útiles} / 438 \text{ B por fila}) = 18 \text{ filas/página}$

$\text{ceil}(1.200.000 \text{ events/día} / 18) = 66.667 \text{ páginas/día}$

$66.667 \text{ páginas} \times 8 \text{ KB/página} = 533.336 \text{ KB}$

$\approx 521 \text{ MB/día}$

8060 B: dato didáctico de espacio útil · 438 B: resultado anterior · 1,2 M/día: dato del caso

Giro del negocio — Hay estacionalidad

No todos los días son iguales

Durante 8 semanas por año, los eventos aumentan 2,5x.

¿Podemos seguir haciendo $521 \text{ MB} \times 365$? Calculen los eventos de un año.

$8 \text{ semanas} \times 7 = 56 \text{ días pico} \cdot 365 - 56 = 309 \text{ días normales}$

Pico diario: $1,2 \text{ M} \times 2,5 = 3,0 \text{ M events/día}$. Ahora calculen events/año y storage anual.

Segundo giro — Cambio de producto

Desde el mes 7

El 5% de los events agrega 200 bytes al payload.

¿Cuánto crece la fila promedio? ¿Qué esperan que pase con el storage?

Primero predigan. Después recalculen filas por página.

La sorpresa física

Un cambio pequeño cruza un umbral

	Antes	Desde mes 7	Impacto
Fila física	438 B	448 B	+2,28%
Filas por página	18	17	-1 fila
Storage diario	≈521 MB	≈551,5 MB	+5,88%

$5\% \times 200 \text{ B} = +10 \text{ B promedio} \rightarrow 438+10=448 \text{ B} \rightarrow 18 \rightarrow 17 \text{ filas/página} \rightarrow \text{casi } +6\% \text{ de storage}$

El almacenamiento físico es discreto: se asignan páginas enteras.

¿Ya terminamos?

Supongamos que la tabla events ocupa ~228 GB/año

¿Comprarán exactamente 228 GB de storage?

¿Qué componentes o riesgos todavía no están en nuestro cálculo?

Anoten todo lo que se les ocurra. No hace falta conocer todavía la fórmula.

Microclase — Un índice también ocupa espacio

Solo la idea necesaria para sizing

event_id		referencia a la fila
10001	→	página X / fila Y
10002	→	página Z / fila W
10003	→	página Q / fila K

Modelo: $\text{entry_size} \approx \text{key_bytes} + 16 \text{ B}$ (16 = 8 B RowID + 8 B overhead)

Para events_pk: key = event_id BIGINT = 8 B. Luego se aplica $\times 1,2$ como 20% extra didáctico por estructura interna.

Trabajo en grupos · no hay una única respuesta si el supuesto está explicitado

Capacity planning

Tamaño de datos $\neq$ capacidad requerida

$$\begin{aligned} & \text{DATOS} \\ & + \text{ÍNDICES} \\ & + \text{LOGS / REDO / WAL} \\ & + \text{ESPACIO OPERATIVO / HEADROOM} \\ & = \text{STORAGE ACTIVO REQUERIDO} \end{aligned}$$

Backups / snapshots / archivo $\rightarrow$ necesidad adicional de protección y retención

Trabajo en grupos · no hay una única respuesta si el supuesto está explicitado

Cierre — Conclusiones

1. ¿Qué supuesto tuvo más impacto?
2. ¿Qué dato del negocio pedirían para mejorar el sizing?
3. ¿Por qué events/día $\times$ 365 era insuficiente?
4. ¿Por qué +10 B/fila produjo casi +6% de páginas?
5. ¿Qué parte del storage requerido no son datos de tablas?

Sizing = modelo defendible + supuestos explícitos + sensibilidad a las variables.