

Lenguajes Relacionales

Una vez realizada la introducción al modelo relacional, es conveniente presentar herramientas para explotarlo. Esta explotación se realiza mediante el uso de lenguajes de consulta, que no son más que una convención o definición que permite la manipulación y la extracción de datos de relaciones en el modelo relacional.

Los lenguajes de consulta con base matemática más difundidos en el ámbito teórico sobre el modelo relacional y que han servido de base para implementaciones comerciales son:

- *Álgebra relacional*: Consiste en una serie de operaciones concebidas para operar con relaciones del modelo relacional, que describen de modo procedural la forma de alcanzar el conjunto (multiconjunto) de respuesta. Es un lenguaje de tipo procedural (se basa en describir "cómo" se alcanza la respuesta) y en la práctica es ampliamente utilizado por los DBMS como representación intermedia de una consulta, tanto para fines de tratamiento, como para fines de optimización (dadas sus propiedades algebraicas).
- *Cálculo relacional*: Consiste en la aplicación de la lógica de predicados en fórmulas (ya sea basándose en tuplas o en dominios) al modelo relacional. Se describe el conjunto (o multiconjunto) deseado. De este modo, a diferencia del álgebra relacional, nos encontramos con un lenguaje de tipo declarativo (se basa no en describir "cómo" se alcanza la respuesta, sino en describir "cómo es" la respuesta).

Operadores del Álgebra Relacional

El álgebra relacional es **cerrada**: cada operador recibe una o más relaciones y produce otra relación como resultado. Esta propiedad permite componer operaciones y construir consultas complejas paso a paso. A continuación se resumen los operadores fundamentales; en todos los casos se asume la semántica de conjuntos del modelo relacional formal, por lo que una relación no contiene tuplas duplicadas.

Operadores unarios

Selección (σ)

La **selección** elige las tuplas de una relación que satisfacen una condición. Puede pensarse como un filtro horizontal: conserva todos los atributos, pero sólo deja pasar las filas para las cuales la condición resulta verdadera. La condición puede comparar un atributo con una constante o con otro atributo de la misma relación, usando $=$, $\neq$, $<$, $\leq$, $>$ o $\geq$; las comparaciones se combinan con AND, OR y NOT.

$\sigma_{\text{condición}}(R)$ Ejemplo: $\sigma_{\text{id_pais} = 1 \text{ AND fecha_ingreso} < '01/01/2005'}(\text{Empleados})$

Es un operador unario. El esquema del resultado es el mismo que el de R y su cantidad de tuplas nunca puede superar a la original. Varias selecciones consecutivas pueden cambiar de orden y también reunirse en una única selección mediante una conjunción.

Proyección (π)

La **proyección** conserva solamente los atributos indicados y descarta los demás; por eso se la interpreta como un recorte vertical de la relación. En el álgebra relacional clásica, que trabaja con conjuntos, también elimina las tuplas duplicadas que pudieran aparecer al suprimir columnas. El grado del resultado coincide con la cantidad de atributos de la lista.

$\pi_{\text{lista de atributos}}(R)$ Ejemplo: $\pi_{\text{legajo, nombre}}(\text{Empleados})$

Si la lista proyectada contiene una clave de R , no se pierden tuplas. Las proyecciones pueden encadenarse sólo si la segunda conserva los atributos que necesitará la siguiente.

Renombre (ρ)

El **renombre** cambia el nombre de una relación, el de sus atributos o ambos, sin modificar sus tuplas. Resulta útil para nombrar resultados intermedios, evitar ambigüedades en una autocombinación y compatibilizar nombres antes de una reunión natural.

$\rho_{S(B1, B2, \dots, Bn)}(R)$ renombra relación y atributos; $\rho_S(R)$ sólo la relación.

Operaciones provenientes de la teoría de conjuntos

La **unión**, la **intersección** y la **diferencia** son operadores binarios y requieren relaciones compatibles con la unión: ambas deben tener el mismo grado y, en cada posición, atributos de dominios compatibles. Los nombres de los atributos del resultado se toman, por convención, de la primera relación.

- **Unión ($R \cup S$):** incluye las tuplas que están en R , en S o en ambas; elimina duplicados.
- **Intersección ($R \cap S$):** incluye únicamente las tuplas que aparecen tanto en R como en S .
- **Diferencia ($R - S$):** incluye las tuplas de R que no están en S . A diferencia de las dos anteriores, no es conmutativa.

Producto cartesiano y reunión

Producto cartesiano ($\times$)

El **producto cartesiano** concatena cada tupla de R con cada tupla de S. No exige compatibilidad con la unión. Si R tiene n atributos y S tiene m, el resultado tiene n + m; si sus cardinalidades son |R| y |S|, se obtienen $|R| \times |S|$ tuplas. Por sí solo suele producir muchas combinaciones sin significado, pero seguido de una selección permite vincular las tuplas relacionadas.

$R \times S$ Ejemplo: Empleados $\times$ Países. Para conservar sólo pares relacionados: $\sigma_{\text{Empleados.id_pais} = \text{Países.id_pais}}$ (Empleados $\times$ Países).

Reunión o join ($\bowtie$)

La **reunión** combina en una única tupla información relacionada que proviene de dos relaciones. El resultado incluye una concatenación de tuplas de R y S sólo cuando la condición de reunión es verdadera. Por ello, una reunión interna equivale conceptualmente a un producto cartesiano seguido por una selección:

$R \bowtie_{\text{condición}} S \equiv \sigma_{\text{condición}}(R \times S)$

La condición compara atributos de ambas relaciones. Si admite cualquiera de los operadores de comparación se habla de **theta join**. Cuando utiliza solamente igualdades se denomina **equijoin**; en este caso los dos atributos comparados permanecen en el resultado, aun cuando contienen los mismos valores.

La **reunión natural** es una variante del equijoin que iguala automáticamente los atributos que tienen el mismo nombre y conserva una sola copia de cada atributo de reunión. Si los atributos relacionados poseen nombres distintos, antes debe aplicarse un renombre. Esta operación debe utilizarse con cuidado: dos atributos homónimos no necesariamente representan el mismo concepto.

Empleados $\bowtie_{\text{Empleados.id_pais} = \text{Países.id_pais}}$ Países (equijoin)
Empleados $\bowtie$ Países (reunión natural, si el atributo común se llama id_pais)

Si ninguna combinación cumple la condición, el resultado es una relación vacía. En el otro extremo, una condición siempre verdadera hace que la reunión degenere en el producto cartesiano. Cuando una relación se reúne consigo misma, es necesario renombrar al menos una de sus apariciones para distinguir los atributos de cada rol.

División ($\div$)

La **división** resuelve consultas que contienen la idea de «para todos». Sean R(Z) y S(X), con $X \subseteq Z$, y sea $Y = Z - X$. El resultado $R \div S$ contiene los valores de Y que aparecen en R combinados con **todos** los valores de X presentes en S. Por ejemplo, permite obtener los empleados que participan en todos los proyectos requeridos.

Participaciones(legajo, id_proyecto) $\div$ ProyectosRequeridos(id_proyecto)

Composición y conjunto completo

Como todo operador produce una relación, el resultado de una operación puede ser la entrada de otra. Una consulta puede expresarse como una fórmula anidada o como una secuencia de pasos con resultados intermedios. La flecha de asignación ($\leftarrow$) se usa para dar nombre a esos resultados.

```
EmpleadosArg  $\leftarrow \sigma_{\text{id\_pais} = 1}(\text{Empleados})$   
Resultado  $\leftarrow \pi_{\text{legajo, nombre}}(\text{EmpleadosArg})$ 
```

El conjunto $\{\sigma, \pi, \cup, \rho, -, \times\}$ es **completo**: cualquier otra operación del álgebra relacional puede expresarse como una secuencia formada con esos operadores. La intersección, las reuniones y la división se conservan como operadores propios porque permiten escribir las consultas de manera más directa y comprensible.

Resumen de notación

Operación	Notación	Resultado
Selección	$\sigma_c(R)$	Tuplas de R que satisfacen c
Proyección	$\pi_L(R)$	Atributos L de R, sin duplicados
Renombre	$\rho_{S(B...)}(R)$	R con nuevos nombres
Unión	$R \cup S$	Tuplas de R, de S o de ambas
Intersección	$R \cap S$	Tuplas comunes a R y S
Diferencia	$R - S$	Tuplas de R que no están en S
Producto	$R \times S$	Todas las combinaciones de tuplas
Theta join	$R \bowtie_c S$	Combinaciones que satisfacen c
Reunión natural	$R \bowtie S$	Equijoin por nombres comunes, sin repetirlos
División	$R \div S$	Valores de R asociados con todos los de S

Síntesis adaptada de R. Elmasri y S. B. Navathe, *Fundamentals of Database Systems*, 7.^a edición, cap. 8, secciones 8.1 a 8.3.

Funciones Agregadas

El conjunto de operadores ya presentados del álgebra relacional no contempla la posibilidad de realizar determinadas funciones matemáticas sobre colecciones de valores, tal como obtener el promedio de notas de un alumno en un cuatrimestre dado. Para eso se definen funciones matemáticas agregadas, entre las cuales se pueden distinguir:

- Suma: Devuelve la sumatoria de un atributo (o formula de atributos) de tipo numérico del conjunto de tuplas con el que se opera.
- Promedio: Devuelve el promedio aritmético de un atributo (o formula de atributos) de tipo numérico del conjunto de tuplas con el que se opera.
- Máximo: Devuelve el máximo valor encontrado de un atributo (o formula de atributos) de tipo numérico del conjunto de tuplas con el que se opera.
- Mínimo: Devuelve el mínimo valor encontrado de un atributo (o formula de atributos) de tipo numérico del conjunto de tuplas con el que se opera.
- Cuenta: Cuenta la cantidad de veces que ocurre un atributo (o formula de atributos) de tipo numérico del conjunto de tuplas con el que se opera.

Todas estas funciones pueden aplicarse en forma sumariada, agrupando las tuplas por un atributo o un conjunto de atributos. Para eso se define una operación del álgebra relacional llamada "**Función**" y representada por el símbolo **F** (llamado "F gótica") cuya sintaxis es:

Lista de atributos por los que se hace el agrupamiento **F** Lista de funciones a aplicar (Relación)

En dónde:

- Lista de atributos por los que se hace el agrupamiento es la lista de atributos de la relación en cuestión por los que se definirán los grupos en los que se realizarán el cómputo de las funciones definidas en Lista de funciones a aplicar
- Lista de funciones a aplicar es la lista de funciones en el formato "función atributo (o fórmula sobre atributos)" que se aplicarán.
- (Relación) es la relación en cuestión, puede obviamente constituirse de la composición de operadores del álgebra relacional.

por ejemplo, volviendo a la relación Empleados:

legajo	nombre	fecha_ingreso	id_pais
131250	Carlos Padilla	15/03/1978	1
131251	Ramiro Ochoa	17/10/2004	1
131252	Daniel Ramirez	10/04/2007	2
131253	Agustín Tarco	25/05/1999	1
131254	Javier Lorkins	15/03/2007	1

si quisiéramos conocer cuántos empleados hay por cada país, podríamos computar:

$$\text{id_pais} \mathbf{F}_{\text{CUENTA (legajo)}}(\text{Empleados})$$

lo que nos devolvería la siguiente relación:

id_pais	CUENTA_legajo
1	4
2	1

Si la lista de atributos de agrupamiento no se especifica (o es nula o vacía), las funciones se aplican sobre toda la relación y devuelven una sola tupla. Cabe destacar por más que parezca que el resultado es escalar, constituye siempre una relación, esta vez compuesta de una sola tupla. Por ejemplo:

$$\mathbf{F}_{\text{CUENTA (legajo)}}(\text{Empleados})$$

devuelve la relación:

CUENTA_legajo
5

Cálculo Relacional

Cómo hemos descrito anteriormente, este lenguaje consiste en la utilización de fórmulas (lógica) para describir la relación resultante. Dado que suponemos que el lector ha hecho los cursos de lógica correspondiente, sólo daremos un breve pantallazo de esta herramienta.

Existen dos variantes del cálculo relacional, una primera llamada Cálculo Relacional de Tuplas, en dónde las variables toman la forma de tuplas, es decir sus valores son tuplas. Y otra variante llamada Cálculo Relacional de Dominios, en dónde las variables toman valores de campos (subcomponentes de las tuplas).

Cálculo Relacional de Tuplas

Una consulta de Cálculo Relacional de Tuplas se expresa de la siguiente manera:

$$\{ T \mid \mathcal{A}(T) \}$$

Dónde:

- T es una variable tipo Tupla. Los cuantificadores "Existe" y "Para Todo" limitan una variable.
- $f(T)$ es una fórmula que describe la variable de Tupla T . Una fórmula es una combinación de fórmulas atómicas. Una fórmula atómica es una combinación mediante operadores lógicos de disyunción, conjunción o negación (*or*, *and*, *not*) de variables y atributos o constantes mediante la utilización de operadores tales como $<$, $>$, $=$, $\neq$, $\leq$, $\geq$. También se considera una fórmula atómica la pertenencia de una tupla a una relación ($t \in R$).

El resultado de esta consulta consiste en el conjunto de todas las tuplas que verifiquen $f(T) = \text{verdadero}$.

Por ejemplo, sobre la relación Empleados, si se desea obtener legajo y nombre de todos los empleados que ingresaron antes de 2005:

$$\{ T \mid \exists M \in \text{Empleados} (M.\text{fecha_ingreso} < 01/01/2005 \text{ and } M.\text{legajo} = T.\text{legajo} \text{ and } M.\text{nombre} = T.\text{nombre}) \}$$

Cómo se vio, para definir el esquema de relación de la relación resultante, se definió la variable de tupla T y solamente se referenció los campos nombre y legajo de la relación Empleados para darle forma a la misma. Desde el punto de vista de la lógica de selección, no sería necesario nombrar ambos campos, pero se lo hace solamente para definir el esquema de relación del resultado.

Cálculo Relacional de Dominios

Aquí las variables recorren los valores de un dominio en particular, pero las reglas son muy similares al cálculo relacional de tuplas, por ejemplo, para realizar la misma consulta en cálculo de dominios, operamos de la siguiente manera:

$$\{ (C1, C2) \mid \exists C3, C4 ((C1, C2, C3, C4) \in \text{Empleados} \text{ and } C3 < 01/01/2005) \}$$

Cómo puede verse, el esquema del resultado es $\{ \text{legajo}, \text{nombre} \}$, cuyo valor es tomado por las variables $C1$ y $C2$. Se cita con cuantificador de existencia a $C3$ y $C4$ (correspondientes con la fecha de ingreso y el país) para poder corresponder con el formato de las tuplas de Empleados y poder aplicar la lógica de selección.

Lenguajes relacionalmente completos

Una vez presentado el álgebra relacional y el cálculo relacional, cabe preguntarse si todo lo que podemos expresar con álgebra relacional se puede expresar en cálculo relacional. Y si todo lo que se puede expresar en cálculo relacional, tiene una correspondencia en el álgebra relacional.

Todo lo que se puede expresar con álgebra relacional, puede expresarse con cálculo relacional (ya sea de dominios o de tuplas, es igual). Ahora, existe un contraejemplo clásico que nos muestra que no todo lo que se expresa en cálculo relacional puede expresarse con álgebra relacional. Veamos la siguiente consulta en cálculo relacional de tuplas:

$$\{ T \mid \text{not } (T \in \text{Empleados}) \}$$

Es decir, se pide un conjunto de tuplas con el formato de la relación Empleados que represente a todas las tuplas que no pertenecen a la relación empleados. Evidentemente el Universo de empleados, visto como el producto cartesiano de todos los dominios de los atributos que lo conforman, es un conjunto infinito, por lo tanto es imposible computar una solución a esta consulta.

Este tipo de consulta es conocida como una consulta insegura. No hay forma de expresar consultas inseguras en álgebra relacional. Sólo pueden expresarse consultas seguras. Para asegurarnos que trabajamos con consultas seguras, se tendrá que asegurar la finitud de la respuesta.

Todo lenguaje de consulta que pueda expresar todas las consultas expresables en álgebra relacional, es considerado relacionalmente completo.

Por tanto el cálculo relacional es relacionalmente completo.

Los lenguajes comerciales (como por ejemplo SQL) generalmente son relacionalmente completos y de hecho tienen una potencia expresiva que generalmente sobrepasa a la del álgebra.

Bibliografía y referencias

- "Sistemas de Bases de Datos - Conceptos fundamentales" - Elmasri/Navathe - Segunda Edición Addison Wesley Iberoamericana.
- "Sistemas de Gestión de Bases de Datos" - Ramakrishnan/Gerke - Tercera edición Ed. McGraw Hill
- "Introducción a los sistemas de Bases de Datos" - C.J. Date - Séptima edición Ed. McGraw Hill
- Wikipedia (<http://wikipedia.org>)